

Master 2 MIAGE — Université Paris-Saclay

UE Projet DATA

Simulateur de Portefeuille Passif avec Régression Linéaire Prédictive

Binôme

BENAMEUR Mostefa

JIRAUD Loic

Encadrant : Nicolas LEGEAY

Année universitaire 2025–2026

Application déployée : <https://<URL-RAILWAY-FRONTEND>>

Code source : https://github.com/akaloic/Financial_dashboard

Table des matières

1	Introduction	1
2	Notions financières mobilisées	1
2.1	ETF (Exchange-Traded Fund)	1
2.2	DCA (Dollar-Cost Averaging)	2
2.3	TER (Total Expense Ratio)	2
2.4	Backtesting et ses limites	3
3	Architecture et choix techniques	3
3.1	Vue d'ensemble	3
3.2	Choix technologiques	3
3.3	Modèle de données	4
4	Pipeline de données	5
4.1	Source : yfinance	5
4.2	Transformations et stockage	5
4.3	Fraîcheur et mise en cache	6
5	Module B — Simulateur DCA	6
5.1	Algorithme	6
5.2	Résultats sur CW8.PA	7
5.3	Comparaison avec un second ETF	8
5.4	Impact du TER	8
5.5	Tests unitaires	8
6	Module C — Régression linéaire OLS	9
6.1	Méthodologie	9
6.2	Résultats numériques	9
6.3	Analyse des résidus	10
6.4	Interprétation critique des résultats	10
7	Qualité du code et tests	12
8	Conclusion	13
8.1	Objectifs atteints	13

8.2	Points forts	13
8.3	Limites et améliorations possibles	14
8.4	Bilan d'apprentissage	14
A	Annexes	15
A.1	Code du moteur DCA	15
A.2	Code du moteur de régression	15
A.3	Captures d'écran complémentaires	15

1 Introduction

L'investissement passif connaît une croissance rapide en France depuis dix ans, portée par la démocratisation des ETF (*Exchange-Traded Funds*) et l'élargissement de leur accès au Plan d'Épargne en Actions (PEA). Là où l'investissement actif cherche à battre le marché par sélection de titres, l'approche passive consiste à répliquer un indice large et à minimiser les frais. La littérature financière documente depuis vingt ans une sous-performance moyenne des fonds actifs après frais par rapport à leurs indices de référence [7], ce qui rend la stratégie passive rationnellement attractive pour un investisseur particulier.

Pour cet investisseur, les choix concrets restent néanmoins complexes : sélectionner un ETF parmi des centaines, en évaluer les frais réels, comparer la performance historique de plusieurs candidats, et arbitrer entre plusieurs stratégies d'apport demandent une compréhension à la fois financière et statistique. Les outils existants (JustETF, Portfolio Visualizer) répondent partiellement à ces besoins mais restent soit généralistes, soit payants, soit limités à des marchés non européens.

Ce projet propose une application web qui répond à trois besoins concrets : explorer les ETF disponibles à partir de données réelles, simuler une stratégie d'investissement programmé (*Dollar-Cost Averaging*) sur historique, et analyser statistiquement la tendance long terme d'un actif via une régression linéaire ordinaire (OLS). L'application n'a pas vocation à fournir des recommandations d'investissement, mais à outiller la décision en rendant explicites les hypothèses, les frais et les limites prédictives de chaque analyse. La discussion critique du module de régression, en particulier, est conçue pour exposer les limites bien identifiées de l'OLS appliqué aux séries temporelles financières plutôt que pour produire des projections fiables.

Le rapport présente d'abord les notions financières mobilisées (section 2), avant de détailler l'architecture technique retenue (section 3) et le pipeline de collecte de données (section 4). Les sections 5 et 6 décrivent respectivement le simulateur DCA et le module de régression, ce dernier incluant la discussion critique sur les limites de l'OLS. La section 7 traite des choix de qualité de code et la conclusion (section 8) revient sur les apports et limites du travail réalisé.

2 Notions financières mobilisées

Cette section présente les concepts financiers au cœur du projet. Leur maîtrise conditionne à la fois la pertinence de la simulation et l'interprétation correcte des résultats de régression.

2.1 ETF (Exchange-Traded Fund)

Un ETF est un fonds coté en bourse qui réplique automatiquement un indice de marché. Acheter une part d'ETF revient à acheter une fraction de l'ensemble des sociétés composant l'indice : un ETF répliquant le MSCI World expose ainsi l'investisseur à environ 1 500 grandes capitalisations mondiales, sans qu'il ait à les sélectionner ni à les pondérer lui-même. Ce mécanisme constitue la base de l'investissement passif : plutôt que de chercher à surperformer le marché par stock-picking, l'investisseur cherche à capturer son rendement moyen avec des frais réduits.

Les ETF présentent deux caractéristiques essentielles pour ce projet. Ils sont liquides : leur cotation est continue en séance, contrairement aux OPCVM traditionnels valorisés une fois par jour. Et leur composition est transparente : la liste exacte des titres détenus et leurs pondérations sont publiées quotidiennement par le gestionnaire. Pour un investisseur résident en France, l'éligibilité au PEA constitue un critère secondaire mais important, car elle permet une fiscalité avantageuse après cinq ans de détention.

Tous les ETF retenus dans ce projet (CW8, ESE, OBLI, et un quatrième en fonction des arbitrages) sont libellés en euros et éligibles au PEA pour ceux qui le permettent.

2.2 DCA (Dollar-Cost Averaging)

Le DCA, ou investissement programmé, consiste à investir une somme fixe à intervalles réguliers — typiquement chaque mois — indépendamment du niveau du marché à cet instant. Le mécanisme produit un effet de lissage : quand les cours baissent, le versement fixe permet d'acquérir mécaniquement plus de parts qu'à un point haut, faisant baisser le prix moyen d'acquisition sur la durée.

Cette stratégie répond à un biais documenté chez l'investisseur particulier, le *market timing* (chercher à entrer au « bon moment »), dont la littérature financière montre qu'il aboutit en moyenne à une sous-performance par rapport à une exposition continue. Le DCA ne garantit pas un meilleur rendement qu'un investissement en bloc dans toutes les configurations de marché — en particulier dans un marché en hausse continue où il est mécaniquement perdant — mais il réduit la variance des résultats et permet à l'investisseur de rester investi de manière disciplinée même pendant les phases de baisse.

Le simulateur du projet reproduit ce mécanisme mois par mois sur dix années de données historiques réelles, ce qui permet à l'utilisateur de visualiser concrètement comment se serait comportée sa stratégie sur plusieurs régimes de marché (haussier 2015-2021, baissier 2022, récupération 2023-2024).

2.3 TER (Total Expense Ratio)

Le TER désigne les frais de gestion annuels prélevés automatiquement par le gestionnaire du fonds, exprimés en pourcentage du capital investi. Un ETF passif sur indice large facture typiquement entre 0,10 % et 0,40 % par an, contre 1,5 % à 2 % pour un fonds géré activement.

L'écart paraît modeste sur une année, mais devient majeur sur une période d'investissement longue par effet de capitalisation. Un différentiel d'un point de pourcentage annuel composé sur trente ans représente une perte de l'ordre de 25 à 30 % du capital final selon le rendement de référence retenu. Le simulateur permet de visualiser cet écart concrètement en superposant deux courbes pour la même stratégie : l'une avec le TER réel de l'ETF, l'autre avec TER nul.

Au-delà du TER affiché, les ETF présentent d'autres frais implicites (spreads à l'achat-vente, optimisation fiscale variable selon réplique physique ou synthétique) que ce projet ne modélise pas pour rester sur les ordres de grandeur dominants.

2.4 Backtesting et ses limites

Le *backtesting* consiste à évaluer une stratégie sur des données passées : on simule mois par mois ce qu'il se serait produit si la stratégie avait été appliquée sur la période. C'est un outil pédagogique précieux pour comprendre les mécanismes en jeu (frais, volatilité, durée de détention), mais il présente des limites fondamentales que le rapport explicite à plusieurs reprises pour ne pas induire l'utilisateur en erreur.

D'une part, les performances passées ne prédisent pas les performances futures : un actif qui a bien performé sur dix ans peut traverser une décennie perdue, comme l'a montré le Nikkei 225 après 1990. D'autre part, le backtesting peut souffrir de plusieurs biais classiques : le *look-ahead bias* consiste à utiliser dans la simulation de l'information qui n'aurait pas été disponible à l'époque ; le *survivorship bias* consiste à ne considérer que les actifs ayant survécu jusqu'à aujourd'hui, en oubliant ceux qui ont disparu.

Le présent projet limite ces biais en travaillant exclusivement sur des ETF toujours cotés à la date du projet, en n'utilisant que les cours de clôture du jour (pas d'information intrajournalière qui aurait pu ne pas être accessible à un particulier de l'époque), et en appliquant les frais réels affichés aujourd'hui plutôt que des frais inventés. La limite résiduelle évidente reste le *survivorship bias* : les quatre ETF retenus ont tous bien performé sur la période, ce qui peut surévaluer l'attractivité de la stratégie DCA dans l'absolu.

3 Architecture et choix techniques

3.1 Vue d'ensemble

L'application suit une architecture trois tiers classique : un frontend React et un backend FastAPI, tous deux hébergés sur Railway, communiquent en HTTP, le backend s'appuyant sur une base PostgreSQL également hébergée sur Railway dans le même projet. Les données financières sont récupérées via la bibliothèque `yfinance` qui interroge l'API publique Yahoo Finance.

La figure 1 synthétise les flux entre composants. Le choix d'une séparation stricte frontend/backend, plutôt qu'une application monolithique avec rendu côté serveur, répond à deux exigences : permettre un déploiement indépendant de chaque tiers (le backend peut être mis à jour sans rebuild du frontend et inversement) et faciliter le développement parallèle au sein du binôme.

[INSÉRER ici le diagramme d'architecture]
[(reprendre celui de docs/ARCHITECTURE.md ou refaire propre)]

FIGURE 1 – Architecture globale de l'application.

3.2 Choix technologiques

Le choix de la stack a été guidé par trois critères : la maturité de l'écosystème pour le calcul scientifique, la facilité de déploiement gratuit, et la cohérence avec la formation M2 MIAGE.

Backend : Python avec FastAPI. Python s'impose pour la chaîne de traitement statistique. Les bibliothèques `Pandas`, `NumPy`, `scikit-learn` et `statsmodels` constituent un standard de facto pour l'analyse de données financières, et leur interopérabilité évite les conversions de format coûteuses. FastAPI a été préféré à Flask et Django pour trois raisons. La documentation Swagger générée automatiquement facilite les tests manuels et la communication avec l'équipe frontend, sans nécessiter d'outil tiers. La validation native via Pydantic v2 évite d'écrire manuellement la couche de vérification des entrées : les contraintes (`capital_initial >= 0`, `ter <= 0.05`) sont déclarées dans les modèles et appliquées à l'arrivée des requêtes, avec un retour 422 explicite en cas d'invalidité. Enfin, FastAPI est sensiblement plus simple à mettre en place que Django pour un projet de cette taille, qui ne nécessite ni l'ORM intégré (SQLAlchemy suffit), ni les vues de gabarits, ni le système d'authentification natif.

Base de données : PostgreSQL. PostgreSQL a été préféré à SQLite pour deux raisons principales. Railway propose un service PostgreSQL géré gratuitement, intégré au même projet que le backend ; aucun setup d'hébergement séparé n'est nécessaire. Et PostgreSQL gère mieux que SQLite les requêtes concurrentes, ce qui peut être utile si plusieurs utilisateurs accèdent simultanément à l'application déployée (typiquement le jour de la soutenance). En contrepartie, PostgreSQL est plus complexe à installer en local sur Windows, ce qui a justifié l'usage de Docker pour le développement local — avec un *fallback* en cas de souci Docker documenté dans le README.

Frontend : React 18 avec Vite. React est le standard du marché pour les SPA (*Single Page Applications*) légères, et l'expertise sur cette stack est attendue au sortir d'un M2 MIAGE. Vite remplace désormais Create React App (officiellement déprécié en 2023) avec un temps de build sensiblement plus rapide grâce à `esbuild` et au transpilage à la demande. Pour les graphiques, Recharts a été retenu pour les courbes DCA en raison de sa simplicité d'intégration et de son rendu propre par défaut, et Plotly pour la régression pour ses fonctionnalités natives de bandes de confiance qui auraient nécessité un développement custom sous Recharts.

Déploiement : Railway. Le projet est entièrement hébergé sur Railway, qui regroupe les trois services (frontend, backend, PostgreSQL) dans un même projet avec un déploiement automatique depuis GitHub à chaque push sur `main`. L'option initiale d'utiliser Vercel pour le frontend (CDN mondial, build Vite optimisé) a été abandonnée en raison d'une restriction d'accès au dépôt GitHub côté Vercel. Le déploiement unifié sur Railway présente l'avantage secondaire de partager les variables d'environnement par référence entre services et de centraliser la facturation et les logs dans un seul tableau de bord. La contrepartie est un CDN moins distribué que celui de Vercel ; pour l'usage attendu (consultations depuis l'Europe pendant la période de soutenance), ce compromis est acceptable. Render avait été envisagé comme alternative pour le backend mais présentait un démarrage à froid plus lent sur le tier gratuit.

3.3 Modèle de données

Cinq tables structurent la persistance des données du projet. Le modèle est volontairement normalisé pour permettre une évolution future (ajout de nouveaux ETF, historisation des simu-

lations utilisateur), tout en restant simple à requêter via SQLAlchemy.

La table `etf` centralise les métadonnées statiques de chaque ETF : ticker yfinance, nom complet, indice répliqué, gestionnaire, TER, éligibilité PEA, devise. Ces données proviennent du fichier `etf_metadata.csv` versionné dans le dépôt, chargé en base au premier démarrage de l'application.

La table `cours_historique` stocke les séries de prix téléchargées depuis yfinance, avec une clé unique sur le couple (`etf_id`, `date`) pour permettre des *upserts* (`INSERT ON CONFLICT DO UPDATE`) lors des mises à jour quotidiennes.

Trois tables persistent les résultats utilisateur : `simulation` stocke les paramètres d'une simulation DCA (capital, versement, dates, TER), `resultat_simulation` stocke les résultats mensuels associés (un enregistrement par mois simulé), et `resultat_regression` stocke les coefficients et métriques de chaque régression effectuée. Cette persistance permet l'endpoint `GET /simulation/{id}` qui retourne les résultats sans recalculer, et constitue une base pour une fonctionnalité future de sauvegarde utilisateur (mentionnée en conclusion).

4 Pipeline de données

4.1 Source : yfinance

La bibliothèque yfinance [5] expose les cours historiques de Yahoo Finance sans clé API et sans limitation explicite pour un usage non abusif. L'appel se résume à quelques lignes :

```
import yfinance as yf
ticker = yf.Ticker("CW8.PA")
hist = ticker.history(period="10y")
```

Le `DataFrame` retourné par `history()` contient les colonnes `Open`, `High`, `Low`, `Close`, `Volume`, `Dividends`, `Stock Splits` indexées par date. La valeur `Close` renvoyée par yfinance est déjà ajustée des dividendes et splits — c'est ce qui distingue `Close` et `Adj Close` dans les sources brutes, mais yfinance applique l'ajustement par défaut. Le projet utilise toujours `Close` pour les calculs DCA et la régression, ce qui garantit la cohérence des comparaisons long terme sur des actifs distribuant des dividendes.

Les métadonnées (TER, indice, éligibilité PEA) ne sont malheureusement pas disponibles via yfinance pour les ETF européens. Yahoo expose bien un objet `ticker.info` pour les actions américaines avec ces informations enrichies, mais la couverture des ETF européens est très incomplète. Le projet maintient donc ces métadonnées dans un fichier `etf_metadata.csv` versionné dans le dépôt, intégré au backend, et chargé en base au premier démarrage.

4.2 Transformations et stockage

Le pipeline appliqué à chaque téléchargement comprend plusieurs étapes successives :

1. Suppression des lignes contenant des `NaN`, qui apparaissent typiquement sur les jours fériés mal annotés ou les suspensions ponctuelles de cotation

2. Normalisation des noms de colonnes en *snake_case* (passage de `Adj Close` à `adj_close`) pour cohérence avec le modèle SQLAlchemy
3. Calcul du delta avec la donnée déjà en base pour ne stocker que les nouveaux points et éviter les doublons, implémenté via la clause `INSERT ...ON CONFLICT DO UPDATE` spécifique à PostgreSQL
4. Mise à jour du champ `derniere_date_cours` de l'ETF pour suivre la fraîcheur des données

L'*upsert* PostgreSQL a été préféré à un `DELETE + INSERT` pour deux raisons : la performance (un seul aller-retour SQL au lieu de deux), et la conservation des éventuelles modifications manuelles en base (utile en cas de correction ponctuelle d'une donnée yfinance erronée).

4.3 Fraîcheur et mise en cache

Interroger yfinance à chaque requête utilisateur serait inefficace et risquerait de faire bannir l'adresse IP du backend par Yahoo, qui applique un *rate limiting* implicite. Le backend met donc en cache les cours en base, avec une fraîcheur de 24 heures : tant que la dernière date de cours stockée date de moins d'une journée, aucune requête yfinance n'est émise.

Sur les jours non ouvrés (week-end, fériés boursiers), cette stratégie est triviale puisqu'aucun nouveau cours ne sera de toute façon disponible. Sur un jour ouvré, elle assure une mise à jour quotidienne à la première sollicitation utilisateur de la journée, ce qui correspond à l'usage attendu (consultation, simulation, pas de *trading* temps réel).

Cette stratégie de cache en base, plutôt qu'en mémoire ou via Redis, a été retenue pour sa simplicité : aucun service supplémentaire à déployer, et la persistance du cache survit aux redéploiements du backend.

5 Module B — Simulateur DCA

5.1 Algorithme

Le simulateur applique mois par mois la stratégie d'investissement programmé. Pour chaque mois de la période demandée, il récupère le prix de clôture du premier jour ouvré, calcule le nombre de parts acquises avec le versement mensuel, met à jour la valeur du portefeuille en appliquant le TER mensualisé, et stocke la ligne en base.

Deux formules pilotent les calculs. La déduction du TER s'applique mensuellement sur la valeur courante du portefeuille (et non sur le capital investi, erreur d'implémentation fréquente) :

$$V_{\text{nette}}(n) = V_{\text{brute}}(n) \times \left(1 - \frac{\text{TER}}{12}\right) \quad (1)$$

Le CAGR (*Compound Annual Growth Rate*) résume la performance annualisée, indépendamment de la durée de simulation :

$$\text{CAGR} = \left(\frac{V_{\text{finale}}}{C_{\text{total versé}}}\right)^{1/n_{\text{années}}} - 1 \quad (2)$$

Une seconde série est calculée en parallèle à titre de référence : la valeur que les mêmes versements auraient produite sur un Livret A, avec le taux courant supposé constant sur la période :

$$V_{\text{LivretA}}(n) = V_{\text{LivretA}}(n-1) \times \left(1 + \frac{i_{\text{LivretA}}}{12}\right) + v_m \quad (3)$$

où v_m est le versement mensuel et i_{LivretA} le taux annuel du Livret A (fixé à 3 % dans la version actuelle, paramétrable). Cette référence sans risque permet de contextualiser la performance de l'ETF pour l'utilisateur. Le code complet de la fonction `run_dca_simulation` est fourni en annexe A.

5.2 Résultats sur CW8.PA

La simulation a été exécutée sur l'ETF de référence du projet, le CW8 d'Amundi qui réplique le MSCI World. Les paramètres retenus correspondent à un cas réaliste d'épargne d'un jeune actif :

- Période : du 1^{er} janvier 2015 au 31 décembre 2024 (10 ans, 120 mois)
- Capital initial : 1 000 €
- Versement mensuel : 200 €
- TER appliqué : 0,38 %

Les résultats obtenus sont synthétisés dans le tableau 1.

TABLE 1 – Résultats de simulation DCA sur CW8.PA (2015–2024).

Métrique	Valeur
Capital total versé	[MONTANT] €
Valeur finale brute (sans TER)	[MONTANT] €
Valeur finale nette (avec TER)	[MONTANT] €
Gain net en euros	[MONTANT] €
Gain net en pourcentage	[POURCENTAGE] %
CAGR net annualisé	[POURCENTAGE] %/an
Valeur équivalente Livret A	[MONTANT] €

La figure 2 superpose trois courbes mensuelles sur toute la période : la valeur du portefeuille avec TER réel, la valeur sans TER (référence théorique), et la valeur équivalente investie sur un Livret A. Cette visualisation permet d'apprécier simultanément l'impact des frais et l'écart d'opportunité par rapport à l'épargne sans risque.

[INSÉRER ici la capture exportée depuis l'application]
[(courbe avec/sans TER + Livret A sur 10 ans CW8)]

FIGURE 2 – Évolution mensuelle du portefeuille DCA sur CW8.PA.

5.3 Comparaison avec un second ETF

La même simulation a été reproduite sur l'ETF ESE.PA (Amundi S&P 500 ESG, TER 0,15 %) afin de comparer l'effet d'un indice plus concentré (États-Unis uniquement) et d'un TER plus faible. Les résultats sont reportés dans le tableau 2.

TABLE 2 – Comparaison des résultats DCA sur deux ETF (2015–2024).

Métrique	CW8.PA (MSCI World)	ESE.PA (S&P 500)
TER appliqué	0,38 %	0,15 %
Valeur finale nette	[MONTANT] €	[MONTANT] €
CAGR net	[POURCENTAGE] %/an	[POURCENTAGE] %/an

[COMMENTAIRE] : décrire en deux ou trois phrases la différence de performance observée. L'ESE.PA devrait surperformer le CW8 sur la période grâce à la forte croissance des grandes capitalisations américaines, à laquelle s'ajoute un TER plus faible. Préciser néanmoins que cette surperformance passée ne préjuge pas du futur, et que la concentration géographique du S&P 500 expose à un risque spécifique au marché américain.

5.4 Impact du TER

L'écart entre la courbe « avec TER » et la courbe « sans TER » sur la simulation CW8 atteint **[MONTANT]** € au terme des dix années, soit **[POURCENTAGE]** % de la valeur finale brute. Cet écart, faible sur les premières années, s'accroît par effet de capitalisation : les frais étant prélevés sur une base qui croît, leur impact absolu augmente mécaniquement. Sur trente ans à conditions équivalentes, l'écart représenterait plusieurs dizaines de milliers d'euros, ce qui illustre concrètement pourquoi le choix d'un ETF à bas TER est un levier majeur de performance pour un investisseur long terme.

Cette observation justifie a posteriori la décision de la majorité des investisseurs particuliers initiés de privilégier les ETF passifs (TER 0,1–0,4 %) plutôt que les fonds gérés activement (TER 1,5–2 %) : l'écart de frais composé sur la durée de détention typique dépasse largement la surperformance moyenne (le plus souvent négative) des fonds actifs [7].

5.5 Tests unitaires

La logique de simulation est couverte par cinq tests `pytest` qui vérifient le comportement sur des cas limites. Le tableau 3 récapitule les tests et leur résultat.

TABLE 3 – Tests `pytest` du moteur DCA.

Nom du test	Cas couvert	Résultat
<code>test_capital_zero</code>	Capital initial nul, premier versement seul	[PASS]
<code>test_ter_zero</code>	TER nul, valeur nette = valeur brute	[PASS]
<code>test_periode_un_mois</code>	Une seule itération de simulation	[PASS]
<code>test_cagr_coherent</code>	CAGR de 0 quand valeur finale = capital versé	[PASS]
<code>test_cagr_invalide</code>	Paramètres invalides retournent 0	[PASS]

Le code des tests est disponible dans `backend/tests/test_dca.py`. La couverture mesurée via `pytest -cov` sur le moteur DCA atteint **[POURCENTAGE]** % de couverture de lignes.

6 Module C — Régression linéaire OLS

Ce module constitue la valeur ajoutée analytique du projet. Au-delà du simple calcul de coefficients, l’objectif est de présenter une analyse nuancée qui mette en évidence les limites de l’OLS appliqué aux séries temporelles financières — limites bien documentées dans la littérature mais souvent ignorées dans les implémentations naïves.

6.1 Méthodologie

Le module ajuste un modèle linéaire simple par moindres carrés ordinaires (OLS) sur l’historique de cours d’un ETF. Les variables sont définies comme suit :

- X : numéro du jour de trading depuis le début de la période, entier croissant $(0, 1, 2, \dots, n-1)$
- Y : prix de clôture ajusté ce jour-là, en euros

Le modèle estimé est $\hat{Y} = \beta_0 + \beta_1 X$, où β_1 représente la variation moyenne du prix par jour de trading sur la période, et β_0 le prix théorique au début de la fenêtre d’analyse.

L’estimation est réalisée avec `statsmodels.OLS`, qui fournit nativement les coefficients, les écarts-types, les p-values, et les intervalles de confiance ; `scikit-learn.LinearRegression` est utilisé en parallèle pour vérifier la cohérence des coefficients estimés et accéder à des prédicteurs vectorisés plus pratiques pour la projection.

Le choix d’une variable explicative discrète (numéro de jour de trading) plutôt qu’une date encodée en *timestamp* ou en fraction d’année se justifie par trois éléments. D’abord, cela évite les problèmes de saisonnalité éventuels (week-ends, fêtes) qui introduiraient un bruit non significatif. Ensuite, β_1 devient directement interprétable comme la variation moyenne quotidienne du prix. Enfin, cela simplifie la projection future en jours de trading sans avoir à manipuler des dates calendaires.

6.2 Résultats numériques

La régression a été appliquée sur la fenêtre 2015–2024 pour deux ETF afin de comparer les comportements. Les résultats sont rassemblés dans le tableau 4.

TABLE 4 – Résultats de régression OLS sur 10 ans de données (2015–2024).

ETF	β_0	β_1 (€/j)	R^2	p-value	DW	N
CW8.PA	[VAL]	[VAL]	[VAL]	[VAL]	[VAL]	[VAL]
ESE.PA	[VAL]	[VAL]	[VAL]	[VAL]	[VAL]	[VAL]

L’interprétation directe des coefficients donne, pour CW8.PA, une variation moyenne du prix d’environ **[VALEUR]** € par jour de trading sur la période, soit environ **[POURCEN-**

TAGE] %/an annualisé sur la base du prix moyen de la fenêtre. Le R^2 de **[VALEUR]** indique que **[POURCENTAGE]** % de la variance du prix est ajustée par la tendance temporelle linéaire. La p-value extrêmement faible (**[VALEUR]**) indique que cette pente est statistiquement très significativement différente de zéro — ce qui n’est pas surprenant sur une série fortement tendancielle de 2 500 observations.

Ces chiffres bruts seront mis en perspective dans la discussion critique (section 6.4) : un R^2 élevé sur une série temporelle financière n’a pas le même sens que sur des données en coupe transversale, et la p-value associée doit être interprétée avec prudence en présence d’autocorrélation.

6.3 Analyse des résidus

L’analyse des résidus permet de vérifier les hypothèses sous-jacentes de l’OLS. Le graphique 3 reporte la série des résidus ($Y_i - \hat{Y}_i$) en fonction du temps pour la régression CW8.

**[INSÉRER ici le graphique des résidus exporté depuis l’application]
[(résidus en fonction du jour de trading sur CW8)]**

FIGURE 3 – Résidus de la régression OLS sur CW8.PA.

Plusieurs caractéristiques sont visibles. Les résidus ne sont pas distribués aléatoirement autour de zéro : ils présentent au contraire des structures temporelles marquées avec des phases prolongées au-dessus ou au-dessous de la droite de régression. Ces phases correspondent typiquement à des cycles de marché identifiables (correction de fin 2018, krach COVID au premier trimestre 2020, baisse 2022 sur les craintes inflationnistes, rebond 2023).

La statistique de Durbin-Watson observée pour CW8 est de **[VALEUR]**, à comparer à la valeur de référence de 2 qui indiquerait l’absence totale d’autocorrélation des résidus. Une valeur proche de zéro, comme observée ici, traduit une autocorrélation positive très forte : chaque résidu prédit fortement le suivant, ce qui constitue une violation flagrante de l’hypothèse d’indépendance des erreurs fondatrice de l’OLS.

6.4 Interprétation critique des résultats

Cette sous-section constitue l’apport principal de l’analyse. Un R^2 élevé sur une série temporelle financière est une statistique trompeuse, et plusieurs limites du modèle OLS doivent être explicitées pour ne pas tirer de conclusions erronées.

R^2 élevé n’implique pas prédictibilité. Un coefficient de détermination proche de 1 indique simplement qu’une droite croissante ajuste bien une série croissante — ce qui est trivialement vrai pour tout actif en tendance haussière long terme. Un investisseur naïf pourrait conclure que le modèle est « bon » et projeter la tendance dans le futur. Mais R^2 mesure l’ajustement en échantillon (*in-sample fit*), pas la capacité prédictive hors échantillon (*out-of-sample*) : il ne dit rien de la pertinence d’une projection future. Le même R^2 élevé pourrait être obtenu sur la

rétrospective des cours du Nikkei 225 entre 1980 et 1989, juste avant deux décennies de baisse continue.

Régression fallacieuse (*spurious regression*). Granger et Newbold [1] ont montré dans un article fondateur que deux séries temporelles non-stationnaires (intégrées d'ordre 1) produisent mécaniquement un R^2 élevé et une p-value très faible, même sans aucun lien économique entre elles. Les cours boursiers sont typiquement non-stationnaires : ils présentent une tendance long terme et une variance évolutive. Régresser un cours boursier sur le temps revient donc à régresser deux variables non-stationnaires l'une sur l'autre, ce qui rend les régressions naïves particulièrement vulnérables à ce phénomène. Un test de Dickey-Fuller augmenté sur les séries utilisées dans le projet confirmerait sans surprise leur non-stationnarité. Une analyse rigoureuse exigerait d'abord de stationnariser les séries (par différenciation ou par passage en log-rendements) avant toute estimation linéaire.

Autocorrélation des résidus. La statistique de Durbin-Watson observée (section 6.3) confirme une forte autocorrélation positive des résidus, ce qui viole l'hypothèse d'indépendance des erreurs de l'OLS. En conséquence, les écarts-types estimés sont biaisés à la baisse, les intervalles de confiance sont trop étroits, et les p-values trop favorables au modèle. Les significativités statistiques affichées dans la sortie standard doivent donc être lues avec prudence : la p-value extrêmement faible obtenue sur β_1 n'est pas surévaluée mathématiquement, mais elle ne signifie pas que le modèle est « fiable » au sens où on l'entendrait dans une expérience contrôlée.

Projection à 12 mois : portée pédagogique uniquement. La projection affichée par l'application extrapole linéairement la tendance passée sur les 252 jours de trading suivant la fin de la période d'estimation. Elle ne prend en compte ni les chocs macroéconomiques (récession, crise géopolitique), ni les changements de régime (hausse de taux, retournement sectoriel), ni la *mean-reversion* caractéristique des excès de marché, ni les phénomènes de volatilité conditionnelle. Elle illustre visuellement le risque qu'il y aurait à se fier à un modèle linéaire pour anticiper les prix, et c'est précisément ce risque que l'application met en évidence en accompagnant la projection d'un avertissement explicite à l'utilisateur.

Modèles alternatifs. Pour une analyse rigoureuse de séries temporelles financières, plusieurs familles de modèles seraient plus appropriées. Les modèles ARIMA permettent de stationnariser préalablement les séries et de modéliser explicitement les composantes autorégressives. Les modèles log-linéaires capturent mieux la croissance exponentielle typique des indices long terme. Les modèles GARCH, classiques en finance, modélisent la variance conditionnelle qui évolue dans le temps (périodes calmes et turbulentes alternent). Plus récemment, des architectures de *deep learning* comme les LSTM ont été appliquées avec un succès mitigé à la prédiction financière. Ces approches dépassent le cadre pédagogique du présent projet, qui se concentre sur l'OLS précisément pour en exposer les limites, mais leur mention dans le rapport contextualise les choix méthodologiques.

Conclusion du module C. La régression OLS appliquée aux cours d'un ETF *confirme une tendance long terme*, ce qui est utile pour valider l'intuition de l'investisseur passif : oui, le MSCI World a globalement progressé sur dix ans, oui la tendance est statistiquement significative. Mais elle *ne fournit pas un outil de prédiction* : la projection à 12 mois doit être lue comme une visualisation pédagogique de la tendance, pas comme une anticipation des prix futurs. C'est précisément cette distinction qui justifie la stratégie DCA décrite dans le module B : plutôt que d'essayer de prédire le marché (ce que ni la régression linéaire ni d'autres modèles ne permettent de façon fiable), il est plus rationnel d'y rester exposé de manière disciplinée sur la durée.

7 Qualité du code et tests

Le code du projet suit plusieurs conventions de qualité standardisées dans l'écosystème Python. Cette section recense les pratiques mises en œuvre et les vérifications effectuées avant la livraison finale.

Gestion des secrets. Les variables sensibles (`DATABASE_URL`, identifiants, URL de production, configuration CORS) sont externalisées dans un fichier `.env` non versionné, lu via `python-dotenv`. Le `.gitignore` exclut systématiquement `.env`, `__pycache__`, `.venv`, et `node_modules`. Un fichier `.env.example` fourni dans le dépôt documente les variables attendues sans exposer de valeur. En production sur Railway, les variables sont configurées dans l'interface web et injectées au runtime sans passer par un fichier.

Documentation API. Chaque endpoint FastAPI est documenté par une docstring qui apparaît automatiquement dans la documentation Swagger générée sur `/docs`. Cette documentation interactive permet à un développeur extérieur (ou au coéquipier frontend) de tester les endpoints sans rédiger de code client, et constitue une référence maintenue automatiquement à jour avec le code.

Validation des entrées. Les schémas Pydantic v2 déclarent les contraintes attendues (`capital_initial >= 0`, `ter <= 0.05`, `date_fin > date_debut`) directement dans les modèles. Les requêtes invalides sont rejetées avec un code HTTP 422 et un message explicite, sans atteindre la logique métier. Cette approche « fail fast » simplifie le code des services qui peuvent supposer la validité de leurs entrées.

Tests automatisés. Les tests `pytest` couvrent les fonctions critiques du moteur DCA (cinq tests, voir tableau 3) et de la régression ([**NOMBRE**] tests vérifiant la cohérence des coefficients sur des séries synthétiques). Les tests sont exécutables localement par `pytest tests/ -v` et pourraient être intégrés à un workflow GitHub Actions pour s'exécuter à chaque pull request, ce qui constituerait une amélioration future.

Structure du projet. La séparation `routers/` / `services/` / `models/` / `schemas/` respecte le pattern recommandé par la documentation FastAPI : les `routers/` exposent les endpoints HTTP

et ne contiennent que de la logique de routage, les `services/` portent la logique métier (calcul DCA, régression), les `models/` décrivent le schéma SQLAlchemy, et les `schemas/` décrivent les contrats Pydantic entrée/sortie. Cette séparation facilite les tests unitaires des services indépendamment de FastAPI.

Déploiement reproductible. La procédure de déploiement (Railway + Vercel) est documentée dans `docs/DEPLOY.md` avec les pièges concrets rencontrés et leurs résolutions. Le `requirements.txt` fige les versions exactes des dépendances pour garantir des builds reproductibles, et le `.env.example` liste les variables attendues. Le README permet à un développeur extérieur de lancer le projet en local en quelques minutes.

8 Conclusion

8.1 Objectifs atteints

Le projet livre une application web complète, déployée sur une URL publique, qui satisfait les trois fonctionnalités attendues : un explorateur d'ETF avec recherche, fiche descriptive et graphique de cours interactif ; un simulateur DCA fonctionnel sur dix années de données réelles, avec comparaison Livret A et illustration de l'impact du TER ; un module de régression OLS avec calcul des coefficients, des intervalles de confiance, projection à 12 mois et discussion critique des limites du modèle.

Les données utilisées sont systématiquement réelles, récupérées via `yfinance` pour les cours et un fichier CSV versionné pour les métadonnées. Aucune donnée fictive n'est présentée à l'utilisateur, même temporairement. Les tests unitaires couvrent les fonctions critiques avec une attention particulière aux cas limites.

8.2 Points forts

Trois éléments distinguent le projet d'une implémentation de base.

D'abord, l'analyse critique du module de régression (section 6.4) va au-delà du simple calcul de R^2 et expose explicitement les limites bien identifiées de l'OLS appliqué aux séries temporelles : régression fallacieuse, autocorrélation des résidus, distinction entre ajustement et prédictibilité. Cette profondeur d'analyse correspond à l'attente explicite du cahier des charges qui fait de cette section la plus discriminante du rapport.

Ensuite, l'application illustre concrètement l'impact des frais (TER) sur la performance long terme, ce qui constitue un apport pédagogique qu'aucun outil grand public ne met aussi explicitement en avant.

Enfin, le déploiement effectif sur une URL publique stable, couplé à une documentation déploiement détaillée incluant les pièges rencontrés, garantit la reproductibilité par un tiers — exigence souvent négligée dans les projets étudiants.

8.3 Limites et améliorations possibles

Plusieurs limites identifiées pointent vers des extensions naturelles du projet.

Le périmètre est volontairement restreint à quatre ETF de référence, ce qui limite la couverture du marché. Une extension naturelle consisterait à intégrer un *scraper* JustETF ou à connecter une API ETF plus complète pour couvrir l'ensemble des ETF européens éligibles PEA.

L'application ne propose pas de persistance utilisateur : l'utilisateur ne peut pas sauvegarder ses simulations ni y revenir. Une couche d'authentification JWT, mentionnée comme bonus dans le cahier des charges, permettrait de stocker l'historique des simulations par utilisateur dans les tables déjà prévues à cet effet.

Le module de régression se limite à l'OLS simple. Les modèles ARIMA, GARCH ou log-linéaires mentionnés dans la critique (section 6.4) seraient plus appropriés analytiquement et constitueraient une extension pédagogiquement riche, en montrant concrètement comment l'analyse change selon le modèle retenu.

Enfin, le test de Dickey-Fuller augmenté évoqué dans la critique de spurious regression pourrait être implémenté pour confirmer quantitativement la non-stationnarité des séries — c'est une amélioration simple à coût faible.

8.4 Bilan d'apprentissage

Le projet a permis de mobiliser conjointement plusieurs compétences développées dans le master : ingénierie de données (pipeline yfinance → PostgreSQL avec gestion de la fraîcheur), architecture logicielle (API REST avec séparation des responsabilités), analyse statistique (régression OLS et discussion critique), et développement frontend moderne (React 18 + Vite).

Au-delà des aspects techniques, le projet a renforcé une compétence souvent sous-évaluée : celle d'identifier les limites de ses propres modèles. L'attractivité d'un R^2 élevé est trompeuse, et l'exigence de discuter les hypothèses statistiques sous-jacentes est un réflexe qui dépasse le cadre de ce projet et trouvera à s'appliquer dans tous les futurs travaux d'analyse de données.

Le déploiement effectif sur Railway, avec les difficultés concrètes rencontrées (encodage PostgreSQL en locale française, gestion des variables d'environnement entre services, configuration CORS, bascule de Vercel vers Railway pour le frontend après un blocage d'accès au dépôt), a également apporté une expérience pratique du *cloud* qui complète utilement la formation purement académique.

Références

- [1] Granger, C. W. J. & Newbold, P. (1974). *Spurious regressions in econometrics*. Journal of Econometrics, 2(2), 111–120.
- [2] Ramírez, S. *FastAPI documentation*. <https://fastapi.tiangolo.com/>, consulté en 2026.
- [3] Seabold, S. & Perktold, J. (2010). *Statsmodels : Econometric and statistical modeling with Python*. Proceedings of the 9th Python in Science Conference.

- [4] Pedregosa, F. et al. (2011). *Scikit-learn : Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825–2830.
- [5] Aroussi, R. *yfinance : Yahoo ! Finance market data downloader*. <https://pypi.org/project/yfinance/>, consulté en 2026.
- [6] Autorité des Marchés Financiers. *Guide de l'investisseur particulier*. <https://www.amf-france.org/>, consulté en 2026.
- [7] S&P Dow Jones Indices. *SPIVA Europe Scorecard*. <https://www.spglobal.com/spdji/>, consulté en 2026.

A Annexes

A.1 Code du moteur DCA

[INSÉRER ici le code complet de la fonction `run_dca_simulation` de `backend/services/dca_engine`

A.2 Code du moteur de régression

[INSÉRER ici le code complet de la fonction `run_ols_regression` de `backend/services/regression`

A.3 Captures d'écran complémentaires

[INSÉRER ici les captures d'écran de l'interface qui n'ont pas trouvé leur place dans le corps du rapport : page Module A avec fiche ETF, page Module B avec formulaire de simulation, page Module C avec graphique de régression et avertissement, vue Swagger de l'API]